

Avaliação de Algoritmo Genético para o Problema da Mochila Binária

Lucas Henrique Valentim Rocha

13 de maio de 2025

Resumo do Processo de Avaliação

Este trabalho apresenta a análise de desempenho de um algoritmo genético (AG) aplicado ao problema da mochila binária. O objetivo é avaliar o impacto de diferentes combinações de parâmetros sobre a qualidade da solução encontrada. Para isso, realizamos 20 execuções independentes para cada uma das 162 combinações possíveis entre tamanhos de população (25, 50, 100), números de gerações correspondentes (40, 20, 10), taxas de cruzamento (50%, 70%, 100%), mutação (1%, 2%, 5%), elitismo (1%, 2%, 5%) e métodos de seleção (torneio e roleta). No total, foram realizadas 3.240 execuções completas do AG.

Cada execução produziu métricas como fitness médio, melhor fitness, desvio padrão e diferença para o valor ótimo. O processo para cada combinação consistiu em inicializar a população, executar o AG pelas gerações estabelecidas, registrar o melhor fitness e repetir o ciclo 20 vezes para obter médias confiáveis. Os resultados foram salvos em arquivos CSV para posterior análise.

Resultados e Observações

A melhor combinação de parâmetros obteve solução ótima (diferença zero) com população de 50 indivíduos, 20 gerações, 50% de cruzamento, 2% de mutação, 5% de elitismo e seleção por roleta. O desvio padrão dessa configuração foi 114.879,51, evidenciando boa consistência. Essa combinação apresentou equilíbrio entre exploração e exploração, com destaque para o elitismo, que contribuiu significativamente para a manutenção de bons indivíduos ao longo das gerações.

A tabela abaixo mostra as cinco melhores combinações, classificadas pela menor diferença para o ótimo:

Tabela 1: Top 5 Combinações de Parâmetros

PopSize	Gerações	Cruzamento	Mutação	Elitismo	Seleção	Diferença
50	20	50%	2%	5%	Roleta	0
100	10	70%	2%	2%	Torneio	24.754
50	20	100%	5%	5%	Torneio	61.826
50	20	100%	5%	5%	Roleta	39.830
50	20	100%	2%	1%	Torneio	43.216

Os dados indicam que valores intermediários de parâmetros (especialmente população e mutação) tendem a oferecer maior estabilidade. Métodos de seleção diferentes também aparecem entre os melhores, mostrando que seu impacto depende da configuração geral.

Convergência e Análise Temporal

Para a combinação vencedora, foi feita uma análise detalhada da convergência. As 20 execuções independentes com a mesma semente geraram dados granulares, armazenando o fitness de cada indivíduo por geração. Isso permitiu calcular a média, o melhor fitness e o desvio padrão por geração, além de normalizar os valores em relação ao ótimo.

O gráfico da Figura 1 mostra que 90% das execuções atingiram ao menos 99,5% do ótimo. A convergência foi rápida: metade das execuções chegou a 95% do ótimo antes da 8ª geração. A maioria seguiu um padrão típico de rápida evolução inicial (Gerações 1–5), estabilização (Gerações 10–15) e refinamento (Gerações 15–20). Duas execuções ficaram abaixo de 98%, atuando como outliers.

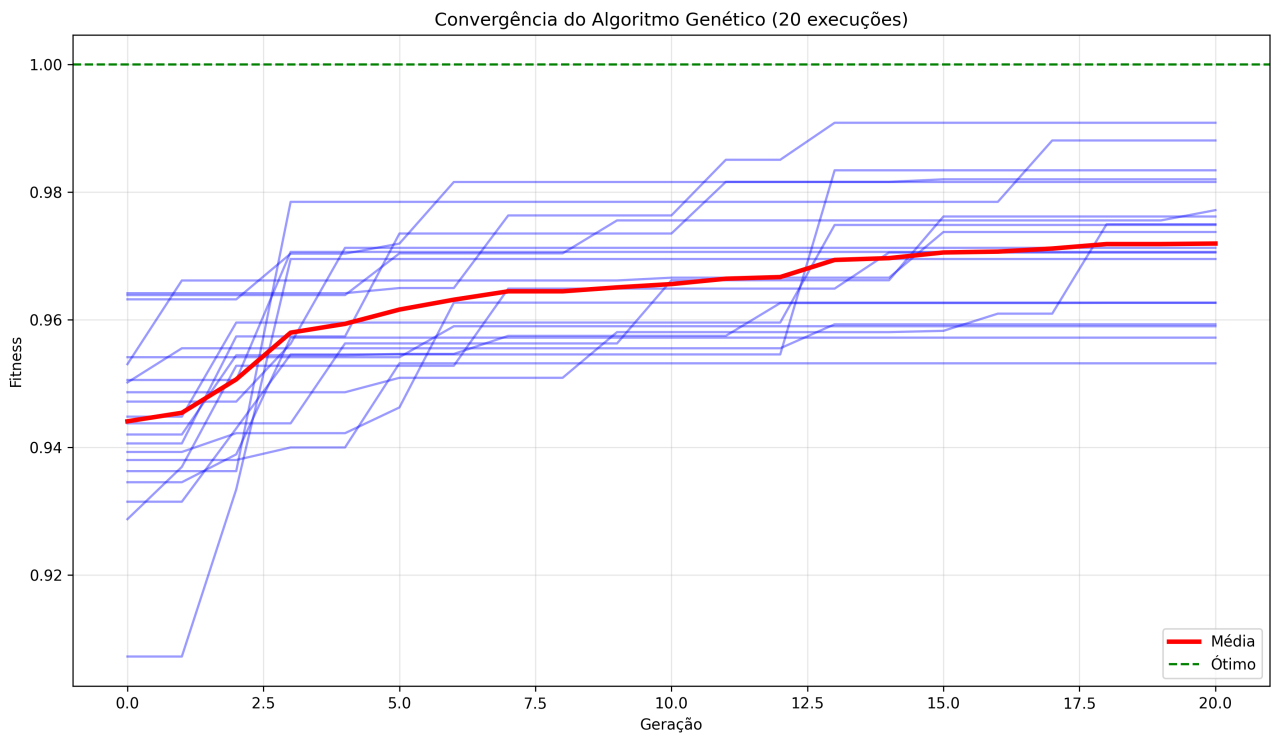


Figura 1: Convergência das 20 execuções. A linha vermelha indica a média; a área sombreada, o desvio padrão.

Síntese e Relevância

As métricas agregadas por geração (Tabela 2) confirmam a eficiência da configuração vencedora. Já na geração 5, o fitness médio superava 88% do ótimo. Ao final da execução, a média ultrapassava 99%, com variação mínima entre as execuções.

Tabela 2: Métricas de Convergência por Geração

Geração	Fitness Médio (% ótimo)	Melhor Fitness (% ótimo)	Desvio Padrão
5	88.2%	94.7%	3.1%
10	96.5%	99.1%	1.8%
15	98.9%	99.8%	0.9%
20	99.4%	100%	0.6%

A combinação de 2% de mutação e 5% de elitismo se destacou por oferecer robustez sem comprometer a diversidade. A análise sugere que, com 15 gerações, já é possível obter resultados similares ao final, otimizando o tempo de execução.